

Popis balíku CZSO IKZ v10 display fixed

Přehled funkcí, význam součástí a rozdíly oproti předchozím verzím

Tento dokument shrnuje aktuální Python bundle „czso_ikz_v10_display_fixed_clean_bundle“. Jde o pracovní pipeline pro výběr, stažení, kontrolu a třídění datasetů ČSÚ pro použití v projektu Index kvality života. Dokument zároveň vysvětluje úlohu jednotlivých notebooků a modulů, význam hlavních vstupů a výstupů a rozdíly mezi nejnovější verzí a staršími generacemi workflow.

1. Co balík jako celek dělá

Balík představuje end-to-end workflow, které z projektového katalogu vybírá relevantní datasety a převádí je do podoby vhodné pro další analytickou práci. Pipeline postupuje po jasných krocích.

- načte katalog czso_katalog_trideny.xlsx,
- vybere datasety relevantní pro IKŽ,
- každý dataset stáhne přes LKOD/VDB nebo přes fallback vrstvu,
- zjistí, zda dataset obsahuje cílové roky, vhodný územní klíč a jakou má územní úroveň,
- vytvoří preview head a tail,
- vyřadí datasety historické nebo bez použitelných previewů,
- seřadí výsledek tak, aby byly nejdříve obce a potom větší územní celky,
- vyrobí manifest, markdown report a další pomocné CSV a XLSX soubory.

Balík je připraven pro dva provozní režimy: plný běh od nuly a rychlý repair nebo reorder nad už existujícím výstupem bez nového stahování všeho.

2. Hlavní notebooky

2.1 CZSO_IKZ_A_to_Z_v10_display_fixed.ipynb

Tohle je hlavní vstupní notebook pro nový běh. Používá se ve chvíli, kdy chceš z katalogu vytvořit celý výstup od začátku.

- načítá katalog,
- vybírá relevantní datasety,
- spouští kompletní pipeline,
- ukazuje manifest_df a souhrnné tabulky,
- na konci zobrazuje výsledky pomocí display_results_by_territory().

Typické parametry, které se v notebooku nastavují: TARGET_YEARS = [2023, 2024],

REQUIRE_ALL_TARGET_YEARS = True, FILTER_PREVIEW_TO_TARGET_YEARS = True, FORCE_REDOWNLOAD, DELETE_DOWNLOADED_FILES_AFTER_PREVIEW, REFRESH_RECENT_SINGLE_YEAR a DROP_ROWS_WITHOUT_PREVIEW.

2.2 CZSO_IKZ_reorder_existing_outputs_v10_display_fixed.ipynb

Tento notebook je určený pro práci nad už hotovým outputem. Nepřegeneruje celý běh od začátku, ale načte existující složku `czso_ikz_a_to_z_output`, znovu aplikuje `postprocessing`, přeuspořádá výstupy a opraví jejich pořadí nebo zobrazení.

Používá se tehdy, když už výstupy existují a potřebuješ jen upravit pořadí, územní scope, manifest nebo report, případně refreshnout jen omezenou sadu problematických datasetů.

2.3 CZSO_IKZ_audit_false_negatives_v10.ipynb

Auditní notebook slouží ke kontrole, zda pipeline omylem nevyřadila dataset, který měl podle zadaných pravidel projít. Porovnává `selected_relevant_catalogue.csv`, `ikz_a_to_z_manifest.csv` a podle potřeby také `dataset_profiles_manifest.csv` ze staršího shortlist workflow.

- hledá silné falešné negativy,
- odděluje technické výpadky od věcných problémů,
- ukazuje datasety, které byly vyřazeny správně jen proto, že jsou historické.

3. Hlavní Python moduly

3.1 czso_ikz_v10_robust_patch.py

To je hlavní logická vrstva celého balíku. Řídí načtení katalogu, stahování datasetů, detekci roků, vytváření previewů a zápis manifestu. Je to hlavní mozek workflow.

Nejdůležitější veřejné funkce tohoto modulu jsou `read_catalogue`, `select_relevant_datasets`, `process_relevant_catalogue`, `repair_existing_output` a `build_summary_tables`.

Uvnitř modulu jsou i klíčové interní skupiny funkcí:

- detekce časových sloupců a roků: `_time_name_priority`, `is_time_like_column_name`, `_extract_years_for_detection`, `parse_year_series`, `_analyse_year_signal`, `_time_candidates_from_probe`, `detect_time_columns_from_probe`, `detect_year_column`;
- filtrování na target years: `mask_series_for_target_years`, `filter_dataframe_to_target_years`, `_years_from_dataframe`;
- robustní práce s CSV: `select_csv_encoding`, `sample_csv_for_time_detection`, `build_probe_from_dataframe`, `_score_csv_probe`, `_mojibake_penalty`;
- načítání previewů z CSV, Excelu, ZIPu a dalších zdrojů;
- stažení datasetu a výběr vhodného souboru;
- CLI parser a main pro běh mimo Jupyter.

3.2 czso_ikz_territory_patch.py

Tento modul řeší interpretaci územní úrovně a pořadí výstupů. Na základě sloupců a preview dat odhaduje, zda dataset patří k obcím, ORP, okresům, krajům, státu, podobecní úrovni nebo ke smíšeným územím.

Hlavní funkce jsou `infer_territorial_scope`, `resort_outputs_by_territory`, `quick_resort_existing_output`, `load_existing_output` a `display_results_by_territory`.

Do této vrstvy byl zapracovaný i display fix. Funkce `display_results_by_territory` dnes umí parametry `categories`, `scopes` a `max_items`, takže je zpětně kompatibilní s novějšími notebooky i staršími buňkami, které používaly filtraci podle kategorií A až D.

3.3 `czso_ikz_audit_false_negatives.py`

To je pomocný modul pro auditní notebook. Obsahuje hlavně funkce `parse_years_any`, `extract_years_from_profile_row`, `read_head_columns` a `run_audit`. Jeho úkolem není generovat previewe, ale kontrolovat, jestli někde nevzniká systematický false negative.

4. Podpůrné moduly a závislosti

4.1 Proč jsou v balíku i starší soubory

V ZIPu jsou i soubory jako `czso_ikz_a_to_z_v5.py`, `czso_ikz_v7_patch.py`, `czso_ikz_v8_clean_patch.py` nebo `_czso_ikz_a_to_z_v4_base.py`. Neznamena to návrat ke staré verzi. Nejnovější v10 je napsaná vrstevně a na tyto starší moduly navazuje. Používá je jako interní kompatibilní stavební bloky.

To je zároveň důvod, proč bylo dříve při míchání ZIPů do jedné složky snadné otevřít starší notebook nebo načíst nečekaný patch modul. V čistém v10 bundle jsou hlavní notebooky už přejmenované tak, aby bylo jasné, že jde o finální verzi.

4.2 `pyczso.py`

Obecný Python klient nad DataStat API ČSÚ. Slouží pro práci s katalogem sad, metadaty datasetů, číselníky a tabulkami získanými přes oficiální DataStat endpointy.

4.3 `pyczso_lkod_bridge.py`

Bridge vrstva pro LKOD, VDB a otevřená data. Používá se pro výběr správné distribuce a stažení souborů tam, kde DataStat není vhodný nebo kde dataset existuje jen ve formě open-data resource. Je důležitá hlavně pro práci se ZIP, CSV a XLSX distribucemi a pro encoding fallback.

4.4 `czso_katalog_trideny.xlsx`

To je vstupní katalog, na kterém je celý workflow postavený. Obsahuje výběr datasetů, jejich relevance pro IKŽ, projektové skupiny, územní úroveň a další metadata. Bez tohoto souboru pipeline neví, které datasety má zvažovat a jak je má kontextově interpretovat.

4.5 `environment_czso_ikz_v10_display_fixed.yml`

Definice conda prostředí pro celý bundle. Obsahuje Python 3.11 a hlavní balíčky jako `pandas`, `requests`, `openpyxl`, `ipykernel`, `jupyterlab`, `nbformat` a další podpůrné knihovny.

4.6 CLI wrappery

V bundle jsou i malé spouštěcí skripty pro běh bez notebooku. Typicky jde o `run_czso_ikz_v10_display_fixed.py`, `repair_czso_ikz_existing_outputs_v10_display_fixed.py` a `run_czso_ikz_audit_false_negatives.py`. Jsou to tenké wrappery, které volají hlavní logiku modulů z příkazové řádky.

5. Hlavní výstupy a jejich význam

5.1 `selected_relevant_catalogue.csv`

Vstupní shortlist všech relevantních datasetů po katalogové filtraci. Je to seznam kandidátů, kteří mají projít pipeline.

5.2 `ikz_a_to_z_manifest.csv` a `ikz_a_to_z_manifest.xlsx`

Finální manifest úspěšně zpracovaných datasetů. Obsahuje klasifikaci, roky, územní scope, primary key, cesty k preview souborům a další auditní informace.

5.3 `ikz_a_to_z_previews.md`

Textový report, ve kterém jsou datasety vypsané ve finálním pořadí a doplněné previewi head a tail.

5.4 `previews`

Adresář obsahující jednotlivé soubory typu `*_head.csv`, `*_tail.csv` a `*_meta.json`. Tyto soubory představují konkrétní preview každého datasetu a metadata nutná pro další audit nebo ruční kontrolu.

5.5 `datasets_by_territorial_scope.csv`

Pomocný přehled datasetů seřazených podle územní úrovně. Slouží ke kontrole, zda je finální pořadí v souladu s logikou obec → ORP → okres → kraj → stát a další úrovně.

5.6 `_downloads`

Dočasná složka pro stažené datasety. Balík je nastavený tak, aby po vytvoření previewů po sobě uklízel a zdrojové soubory z této složky mazal, pokud výslovně nezvolíš jejich ponechání.

6. Hlavní rozdíly mezi nejnovější verzí a staršími verzemi

6.1 Původní A-to-Z workflow

První generace uměla vybrat relevantní datasety, klasifikovat je do kategorií A až D a vytvořit previewe. Její slabinou byla méně robustní heuristika pro detekci roků a slabší práce s různými typy zdrojů.

6.2 Verze v5

v5 opravila falešné target years ze sloupců typu hodnota, zavedla filtrování previewů jen na target years a stabilizovala základní logiku pro roky 2023 a 2024. Zůstalo také automatické čištění downloadů po vytvoření previewů.

6.3 Verze v6

v6 přidala territorial reorder nad už hotovým outputem. Umožnila tedy rychlé přeuspořádání manifestu bez několika hodin nového stahování.

6.4 Verze v7

v7 zavedla historický cutoff pro datasety starší než 2020, zvláštní zacházení pro jednoleté snapshot datasety 2020 až 2023 a řazení ročních variant stejné rodiny za sebe.

6.5 Verze v8

v8 vyčistila výstupy tak, aby se ve finálním reportu neobjevovaly datasety bez použitelných head a tail previewů. Současně zavedla archivaci vyřazených previewů.

6.6 Verze v8.1

Malý opravný krok, který sjednotil název sloupce relevance_pro_IKZ versus relevance_pro_ikz a odstranil pády notebooků na KeyError.

6.7 Verze v9

v9 výrazně zpřísnila heuristiku pro detekci času. Sloupce typu hodnota, idhod, *_kod, *_cis, *_txt nebo vuk už se automaticky nepovažovaly za kandidáty na časový sloupec.

6.8 Verze v10 robust

To je největší metodický skok oproti starším verzím. V10 řeší tři důležité systematické chyby: časový sloupec omylem vyřazený kvůli názvu obsahujícímu kod, selhání na velkých CSV, kde validní roky nejsou v prvních 100 řádcích, a problémy s kódováním souborů.

- whitelist časových názvů má přednost před blacklistem,
- časové sloupce se hledají z průběžného vzorku přes celý velký CSV, ne jen z prvních řádků,
- encoding se vybírá robustněji mezi více variantami UTF a Windows kódování,
- je přidán audit false negatives jako samostatná vrstva kontroly.

6.9 V10 display fixed clean

Poslední čistý bundle přidal opravou display vrstvy kompatibilní funkci

display_results_by_territory(categories=..., scopes=..., max_items=...) a sjednotil názvy notebooků na v10.

Cílem bylo odstranit zmatek vznikající při míchání více starších ZIP bundle do jedné složky.

7. Pozdější doplňky mimo původní clean bundle

7.1 CZSO_IKZ_manifest_plus_excluded.ipynb

Doplňkový notebook, který vytváří nový XLSX soubor se dvěma sheety: manifest a excluded. Sheet manifest kopíruje finální úspěšně zpracované datasety a sheet excluded doplňuje seznam datasetů, které byly ze shortlistu vyřazený.

7.2 Opravený audit notebook

Auditní notebook dostal dodatečný hotfix, aby nehledal selected_relevant_catalogue.csv jen v jedné konkrétní složce, ale uměl ho dohledat i v běžných výstupních adresářích. To odstranilo FileNotFoundError při spuštění v nové pracovní složce.

8. Doporučené použití

- Pro nový běh od nuly použij CZSO_IKZ_A_to_Z_v10_display_fixed.ipynb.
- Pro opravu nebo přeuspořádání existujících výstupů použij CZSO_IKZ_reorder_existing_outputs_v10_display_fixed.ipynb.
- Pro kontrolu možných falešných negativů použij CZSO_IKZ_audit_false_negatives_v10.ipynb.

- Pokud chceš zachovat přehled o vyřazených datasetech v Excelu, doplň si do pracovní složky i notebook CZSO_IKZ_manifest_plus_excluded.ipynb.

Nejdůležitější praktické pravidlo je pracovat vždy v nové čisté složce a nemíchat do ní starší bundle.

Samotná v10 je funkčně navázaná na starší vrstvy, ale hlavní notebooky a moduly mají být v pracovním adresáři vždy jen v jedné, aktuální kombinaci.

9. Stručné shrnutí

Nejnovější bundle v10 display fixed představuje robustní pracovní pipeline pro výběr a profilaci datasetů ČSÚ pro projekt IKŽ. Oproti starším verzím je přesnější v detekci roků, stabilnější při práci s velkými CSV a kódováním, má zvládnuté územní řazení a navíc obsahuje auditní vrstvu pro kontrolu systematických chyb. Hlavní pracovní notebook pro nový běh je CZSO_IKZ_A_to_Z_v10_display_fixed.ipynb, hlavní logika je v czso_ikz_v10_robust_patch.py a územní řazení a zobrazení řeší czso_ikz_territory_patch.py.